AI per la produttività

Come l’AI e l’open source si integra nei processi
Per aziende e progetti personali

Luca Miglioli - 24 Ottobre 2026

Chi sono io?

Luca Miglioli

- Ragazzo 22enne
- Studio reti neurali e modelli di linguaggio da 4 anni, da reti convoluzionali per immagini nel 2022 ai transformer di oggi su testo, immagini ecc...
- Sto seguendo vari progetti in aziende di Brescia per semplificare processi e in alcuni casi automatizzarli con AI. Come libero professionista - sviluppatore software

Talk passati...

Neural accelerators

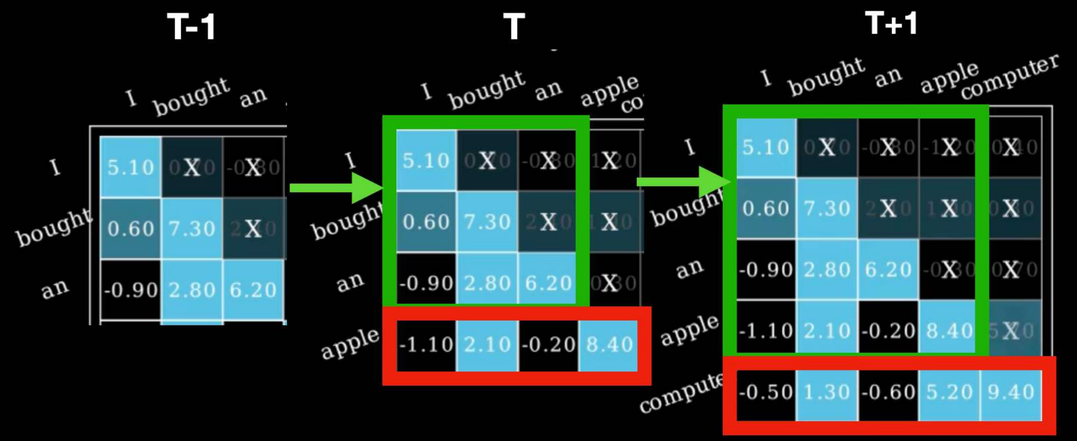
Apple M1



*(Values in this attention matrix are AI generated)

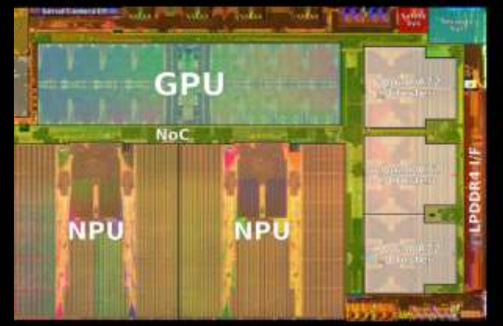
KV Cache

Looking at the attention matrices at steps t-1, t and t+1



The only part that changes is the last token, we don't need to recompute the whole matrix

elerators



Binary classification

Understanding the fundamental

```python
# Parameters
m = torch.zeros(784).requires_grad_()
q = torch.zeros(1).requires_grad_()

# Training hyperparameters
epochs = 50
lr = 1e-3 #  1*10^-3 = 0.001

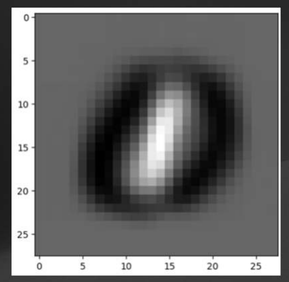
# Training loop
for epoch in range(epochs):
    # Forward pass
    # How shapes work in pytorch matrix multiplications: [8000, 784] @ [784] = [8000]
    pred = F.sigmoid(images @ m + q)  # formula for perceptron with sigmoid activation
    loss = ((pred - labels)**2).mean()

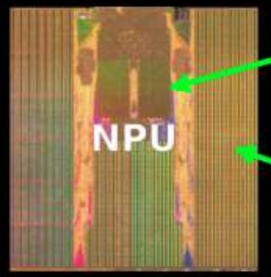
    # Backward pass
    loss.backward()
    with torch.no_grad():
        m -= lr * m.grad
        q -= lr * q.grad
        m.grad = None
        q.grad = None

    # Print loss every 10% of epochs
    if epoch % (epochs//10) == 0:
        print(f'Epoch {epoch}/{epochs} - Loss: {loss.item()} - Accuracy: {round(((pred.round() ==
```

Python

```
Epoch 35/50 - Loss: 0.22 - Accuracy: 98%
Epoch 40/50 - Loss: 0.22 - Accuracy: 98%
Epoch 45/50 - Loss: 0.22 - Accuracy: 99%
```





NPU (96x96 Mul/Add array)
9216 MACs @ 2GHz
36TOPs

SRAM (32MB)
512B/clock @ 2GHz
1TB/s

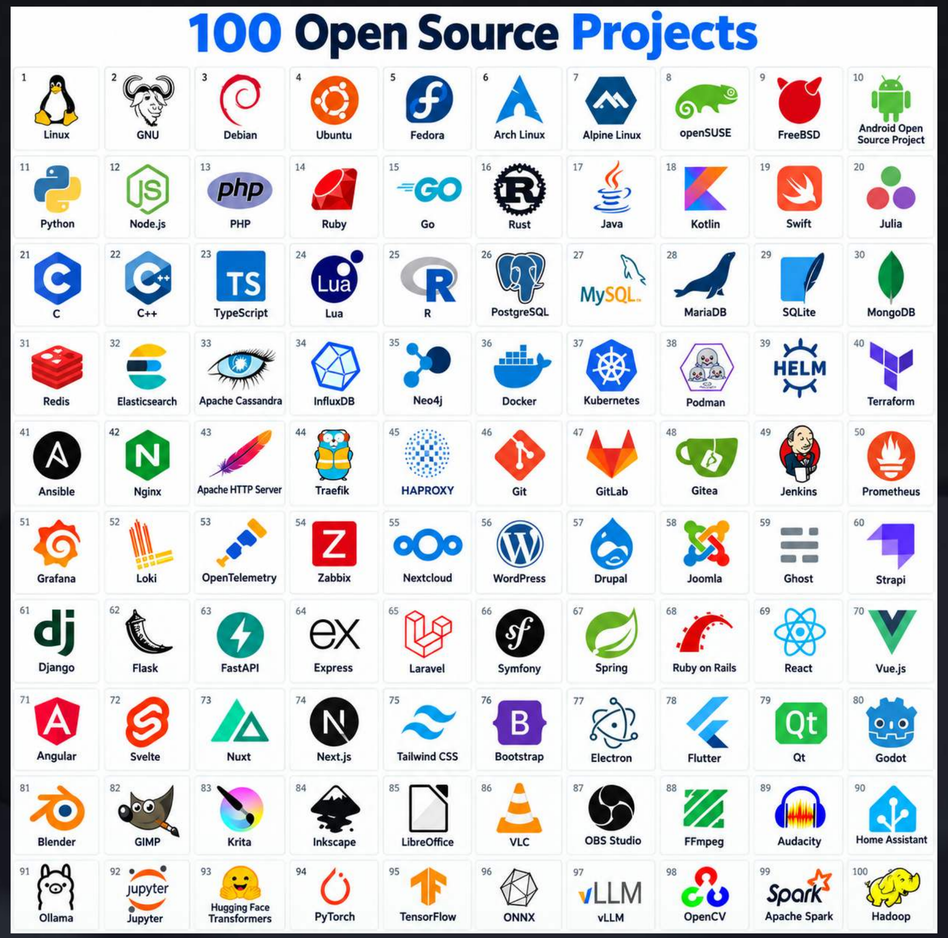
68GB/s to DRAM

Di cosa parliamo oggi

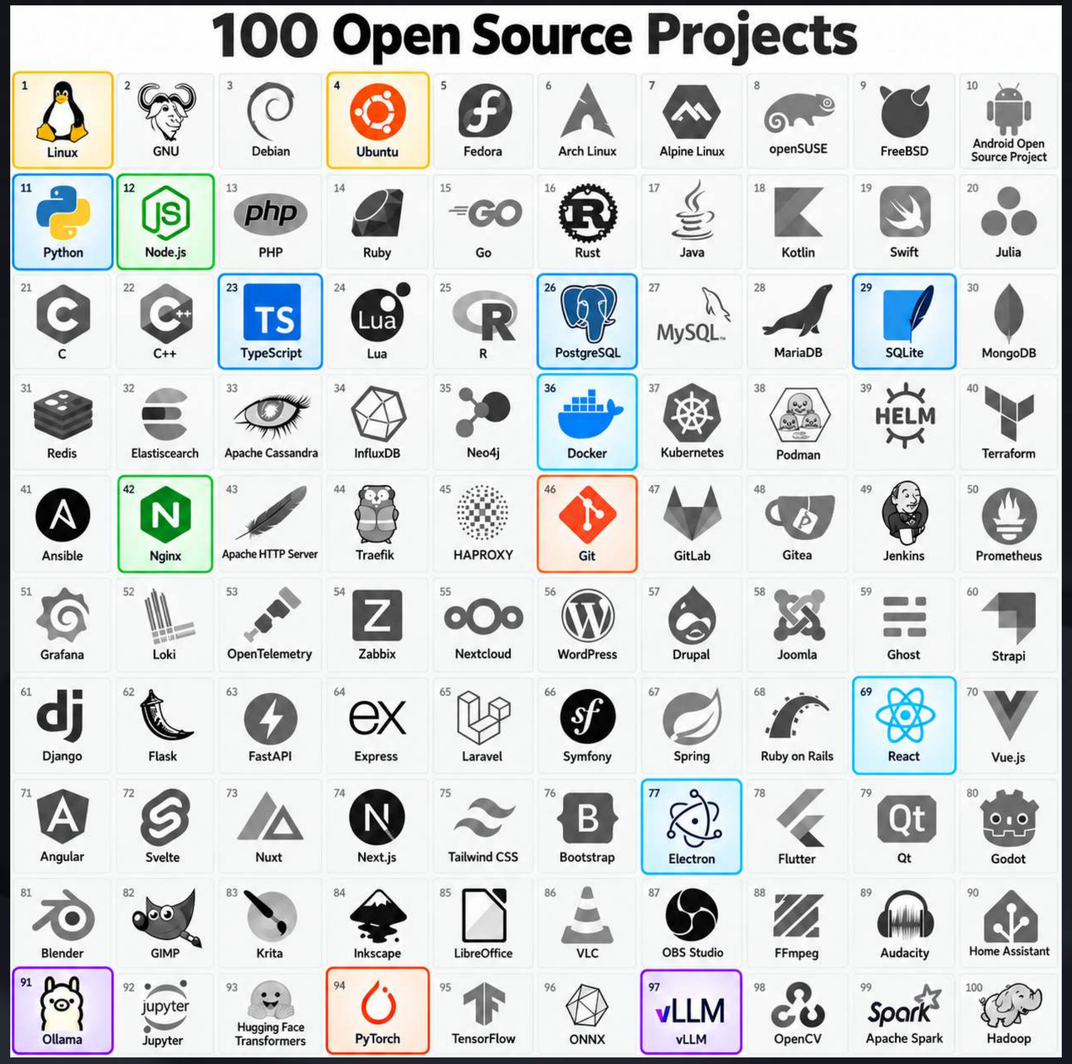
Come usare l’AI per interagire col mondo open source

Di cosa parliamo oggi

Come usare l'AI per interagire col mondo open source



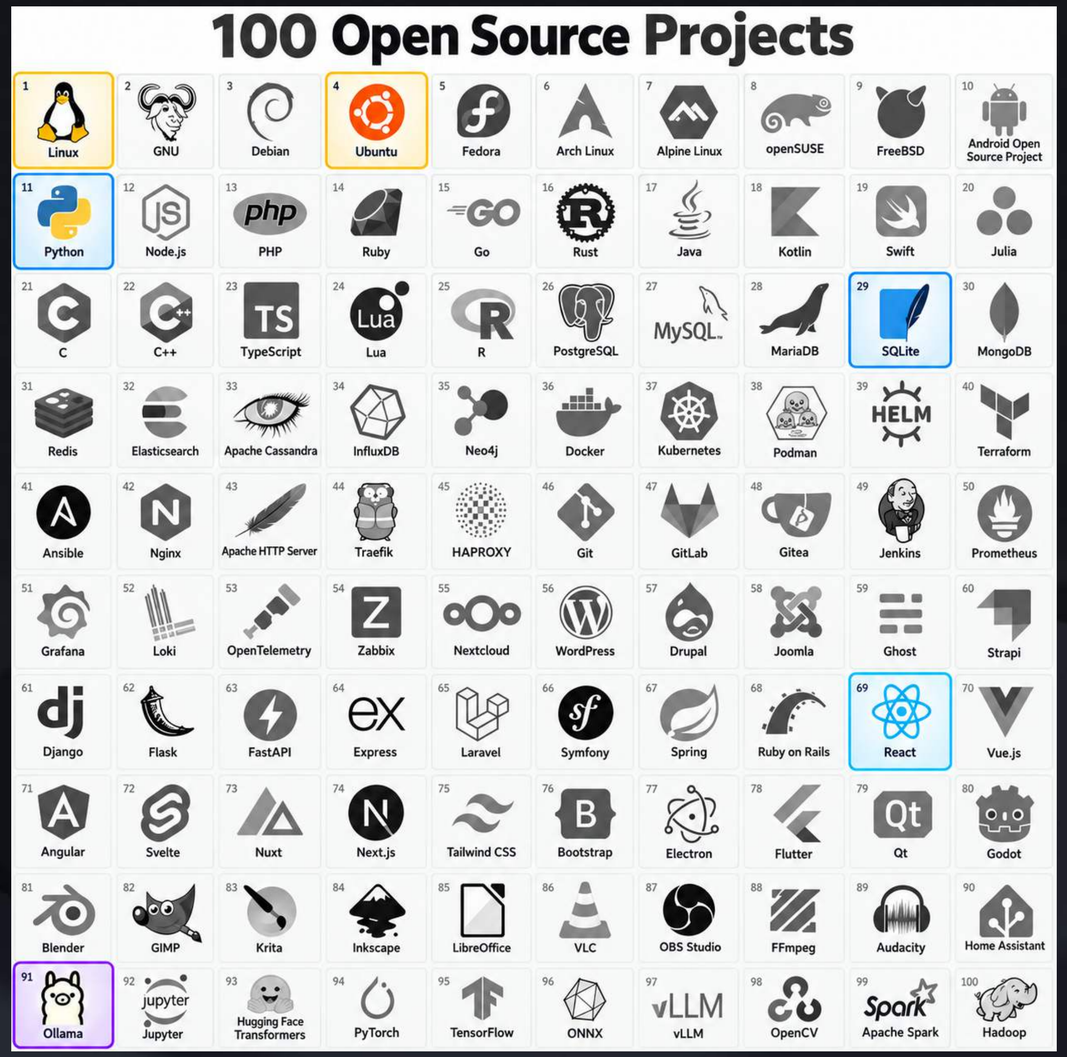
Progetti open source che uso io



Progetti open source che vediamo oggi

Linux
Python
SQLite
React

e Ollama



Ok, ci sono tante cose open source...

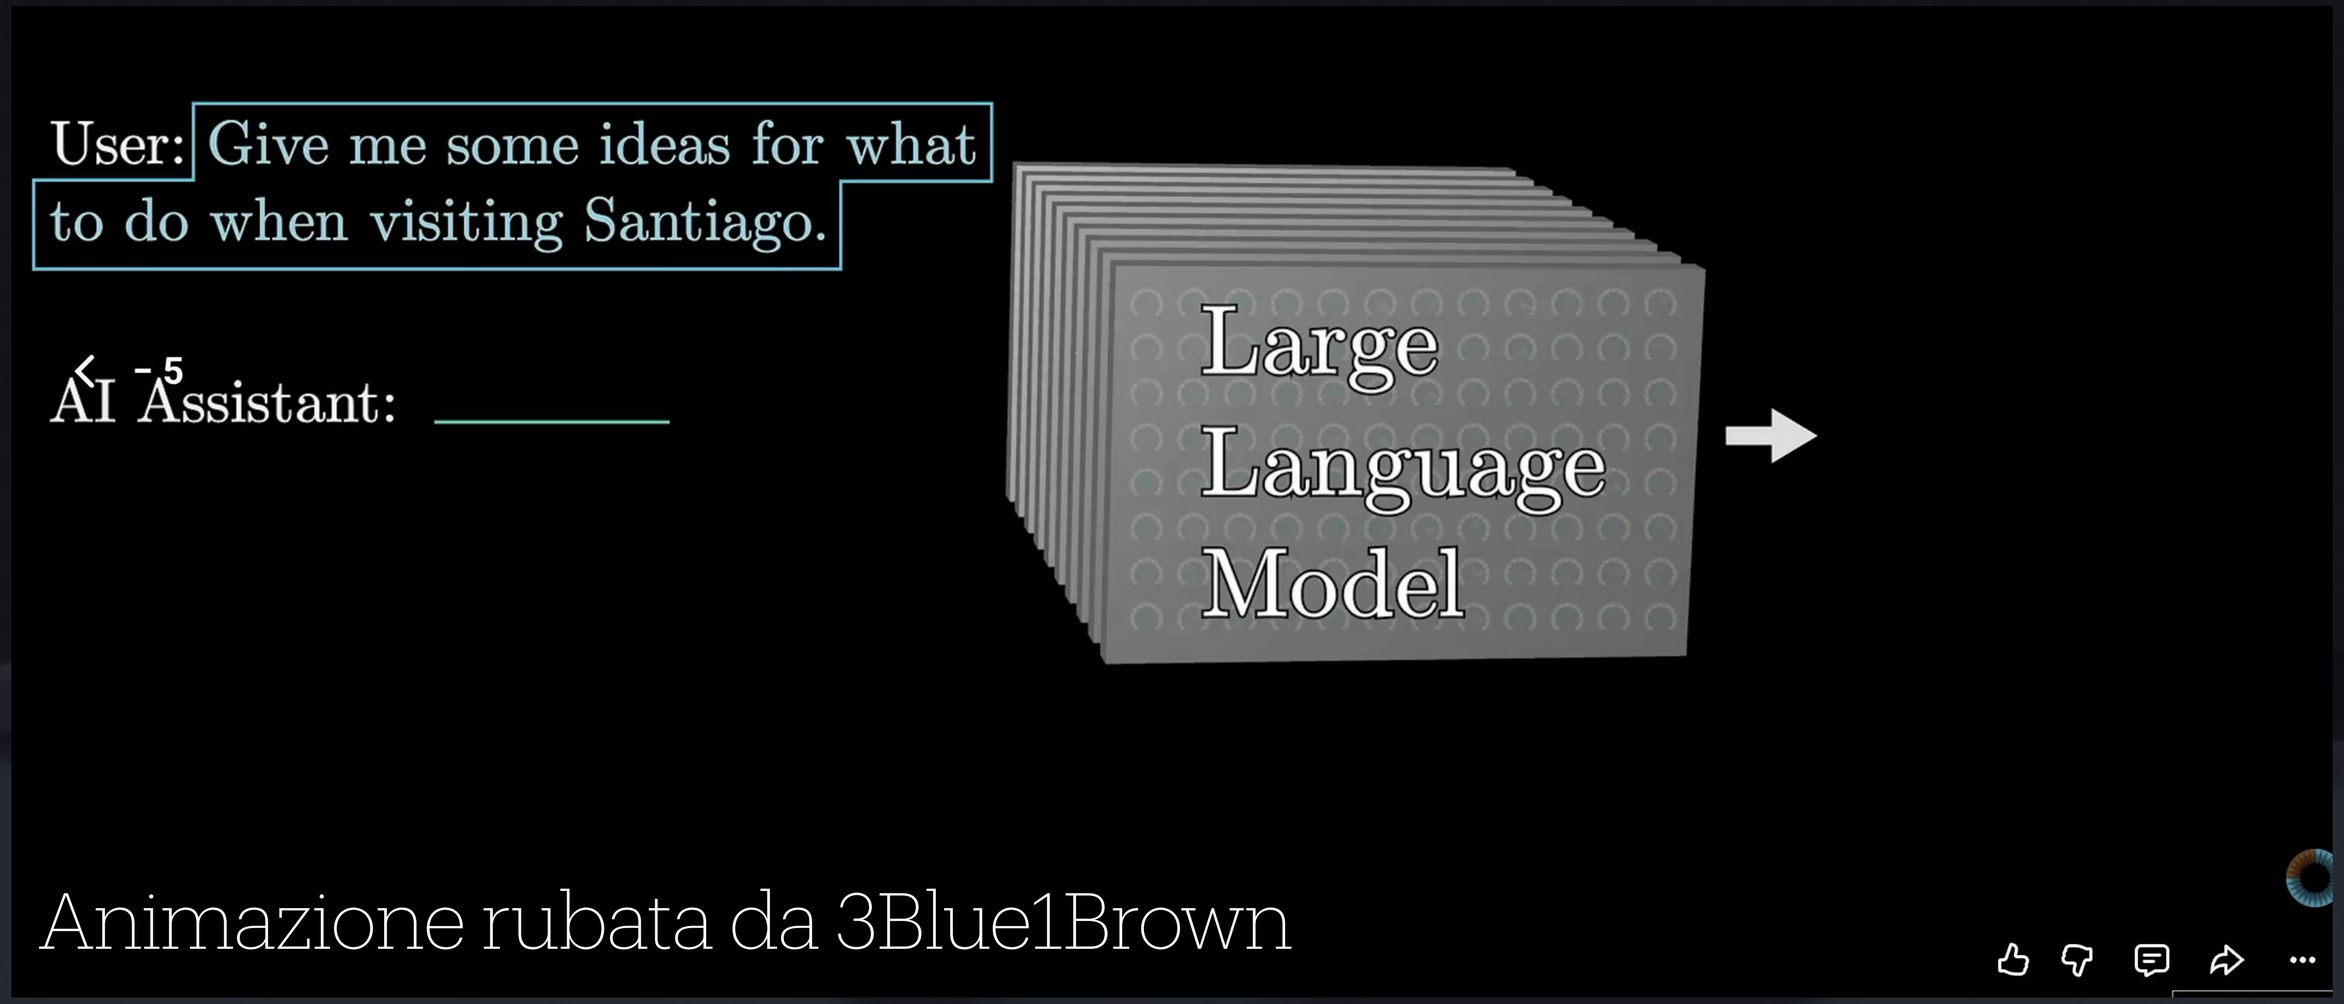
Ma cosa sono e come le posso usare?

- Iniziamo facendo uno schema di un app
- Poi lo passiamo a codex
- E testiamo l’app prodotta

Pausa dalla presentazione...

Tornando a noi…

Il risultato è assurdo ma come funziona? Partiamo dall'inizio, con gli LLM



Animazione rubata da 3Blue1Brown

Pipeline di addestramento di un assistente GPT

Fase	Pre-addestramento	Fine-tuning supervisionato (SFT)	Modellazione della ricompensa (RM)	Apprendimento per rinforzo (RL)
Dataset	**Testi grezzi da Internet** Migliaia di miliardi di parole Qualità bassa, quantità elevata	**Dimostrazioni** Risposte ideali dell'assistente ~10–100 mila coppie (prompt, risposta), scritte da collaboratori Quantità bassa, qualità alta	**Confronti** ~100 mila – 1 milione di confronti, effettuati da collaboratori Quantità bassa, qualità alta	**Prompt** ~10–100 mila prompt scritti da collaboratori Quantità bassa, qualità alta
Algoritmo	**Modellazione del linguaggio** prevedere il token successivo	**Modellazione del linguaggio** prevedere il token successivo	**Classificazione binaria** prevedere ricompense coerenti con le preferenze umane	**Apprendimento per rinforzo** generare token che massimizzano la ricompensa
Modello	**Modello di base**	**Modello SFT** inizializzato dal modello di base	**Modello RM** inizializzato dal modello SFT	**Modello RL** inizializzato dal modello SFT e utilizza il modello RM
Note	Migliaia di GPU Mesi di addestramento Esempi: GPT, LLaMA, PaLM **Il modello può essere distribuito e utilizzato**	1–100 GPU Giorni di addestramento Esempio: Vicuna-13B **Il modello può essere distribuito e utilizzato**	1–100 GPU Giorni di addestramento	1–100 GPU Giorni di addestramento Esempi: ChatGPT, Claude **Il modello può essere distribuito e utilizzato**

Gli LLM in pratica

3 distro linux piu popolari?

Thought for 50.9 seconds

Le tre distro Linux più diffuse e popolarmente utilizzate oggi sono generalmente considerate:

1. **Ubuntu**: È probabilmente la più popolare per i suoi utenti finali grazie alla sua facilità d'uso, supporto costante (versioni LTS) e ampia compatibilità con hardware e software.
2. **Debian**: Fondamentale per chi cerca stabilità e sicurezza, è spesso scelta da sviluppatori e amministratori che preferiscono una base solida su cui costruire altri sistemi.
3. **Fedora**: È la più scelta per le esigenze di sviluppo open source e per utenti che cercano aggiornamenti frequenti e strumenti moderni.

Nota: La popolarità può variare leggermente in base a criteri specifici (downloads vs comunità, supporto aziendale, ecc.), ma queste tre coprono la maggior parte dei casi.

qual'è l'ultima versione di ubuntu disponibile?

Thought for 3.7 seconds

L'ultima versione della distribuzione di base **Ubuntu** disponibile è quella dell'ultima versione LTS (Long Term Support), che attualmente è la:

- **Ubuntu 24.04 LTS** ("Noble Numbrix") – disponibile da circa la fine di giugno 2023, con supporto fino al 2030.

Questo è Ollama



qual'è l'ultima versione di ubuntu disponibile?

Al **21 ottobre 2026**, le ultime versioni di Ubuntu sono:

Versione	Rilascio	Supporto
Ubuntu 26.10 (ultima)	15 ottobre 2026	Luglio 2027
Ubuntu 26.04 LTS (ultima LTS)	Aprile 2026	Maggio 2031

La **26.10** include Linux Kernel 7.3, GNOME 51 e Python 3.14. Lista di Mail... +1

Consiglio: usa Ubuntu 26.04 LTS per server, Docker e ambienti di produzione. La 26.10 è più indicata per sperimentare le ultime novità.

Download: Ubuntu ufficiale ↗.

<- ChatGPT

Perche sbagliano?

I limiti del training

- Gli LLM sono modelli statistici allenati a prevedere correttamente la parola successiva.
- Hanno una knowledge cutoff date (la conoscenza si ferma ad una certa data)
- è sbagliata la concezione che “imparano” nel tempo

qual'è l'ultima versione di ubuntu disponibile?

Al **21 ottobre 2026**, le ultime versioni di Ubuntu sono:

Versione	Rilascio	Supporto
Ubuntu 26.10 (ultima)	15 ottobre 2026	Luglio 2027
Ubuntu 26.04 LTS (ultima LTS)	Aprile 2026	Maggio 2031

La **26.10** include Linux Kernel 7.3, GNOME 51 e Python 3.14. Lista di Mail... +1

Consiglio: usa Ubuntu 26.04 LTS per server, Docker e ambienti di produzione. La 26.10 è più indicata per sperimentare le ultime novità.

Download: Ubuntu ufficiale ↗.

<- ChatGPT

qual'è l'ultima versione di ubuntu disponibile?

Ollama ->

In base ai risultati ufficiali di Ubuntu, l'ultima versione disponibile è:

- **Ubuntu 26.10** ("Stonking Stingray") – l'ultima release standard disponibile.

Se invece intendi l'ultima versione LTS (Long Term Support), è:

- **Ubuntu 26.04.1 LTS** ("Resolute Raccoon").

Come fanno a dare le risposte giuste

se non sono allenati su ciò che stiamo chiedendo?

- Come faresti tu a rispondere ad una domanda a cui non sai la risposta?

qual'è l'ultima versione di ubuntu disponibile?

<- ChatGPT

Al **21 ottobre 2026**, le ultime versioni di Ubuntu sono:

Versione	Rilascio	Supporto
Ubuntu 26.10 (ultima)	15 ottobre 2026	Luglio 2027
Ubuntu 26.04 LTS (ultima LTS)	Aprile 2026	Maggio 2031

La **26.10** include Linux Kernel 7.3, GNOME

Consiglio: usa Ubuntu 26.04 LTS per serv
sperimentare le ultime novità.

Download: Ubuntu ufficiale ↗.

qual'è l'ultima versione di ubuntu disponibile?

Ollama ->

Searched the web for 2.8 seconds

In base ai risultati ufficiali di Ubuntu, l'ultima versione disponibile è:

- **Ubuntu 26.10** ("Stonking Stingray") – l'ultima release standard disponibile.

Se invece intendi l'ultima versione LTS (Long Term Support), è:

- **Ubuntu 26.04.1 LTS** ("Resolute Raccoon").

Tool di ricerca web sono molto comodi

Quando cerchiamo su internet spesso guardiamo 1-3 siti...
Un LLM ne guarda decine in pochi secondi...

Che altri tool possiamo avere?

Calcolatrice
Calendario
Memoria
Genera immagine

Leggi/scrivi su file:

- Excel
- Word
- Powerpoint

fammi un preventivo per il progetto consegne del latte

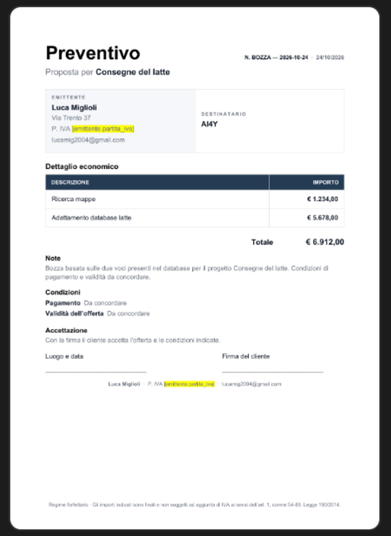
▼ Dettagli

▸ **inspect_database** sandbox/databases/gestione.sqlite

▸ **read_data** sandbox/databases/gestione.sqlite

▸ **use_template** {}

▸ **use_template** W preventivo_Consegne_del_latte_2026-10-24.docx OPEN



Preventivo

N. BOZZA — 2026-10-24 · 24/10/2026

Proposta per **Consegne del latte**

EMITTENTE
Luca Miglioli
Via Trento 37
P. IVA [omissis partita_iva]
lucamig2004@gmail.com

DESTINATARIO
AI4Y

Dettaglio economico

DESCRIZIONE	IMPORTO
Ricerca mappe	€ 1.234,00
Adattamento database latte	€ 5.678,00
Totale	**€ 6.912,00**

Note
Bozza basata sulle due voci presenti nel database per il progetto Consegne del latte. Condizioni di pagamento e validità da concordare.

Condizioni
Pagamento Da concordare
Validità dell'offerta Da concordare

Accettazione
Con la firma il cliente accetta l'offerta e le condizioni indicate.

Luogo e data

Firma del cliente

Luca Miglioli · P. IVA [omissis partita_iva] · lucamig2004@gmail.com

Regime forfettario · Gli importi indicati sono finali e non soggetti ad aggiunta di IVA ai sensi dell'art. 1, commi 54-89, Legge 190/2014.

preventivo_Consegne_del_latte_2026-10-24.docx · p.1

Scarica il preventivo Word per **AI4Y — Consegne del latte**.

Ho incluso le due voci presenti nel database:

- Ricerca mappe: **€ 1.234,00**
- Adattamento database latte: **€ 5.678,00**
- **Totale: € 6.912,00**

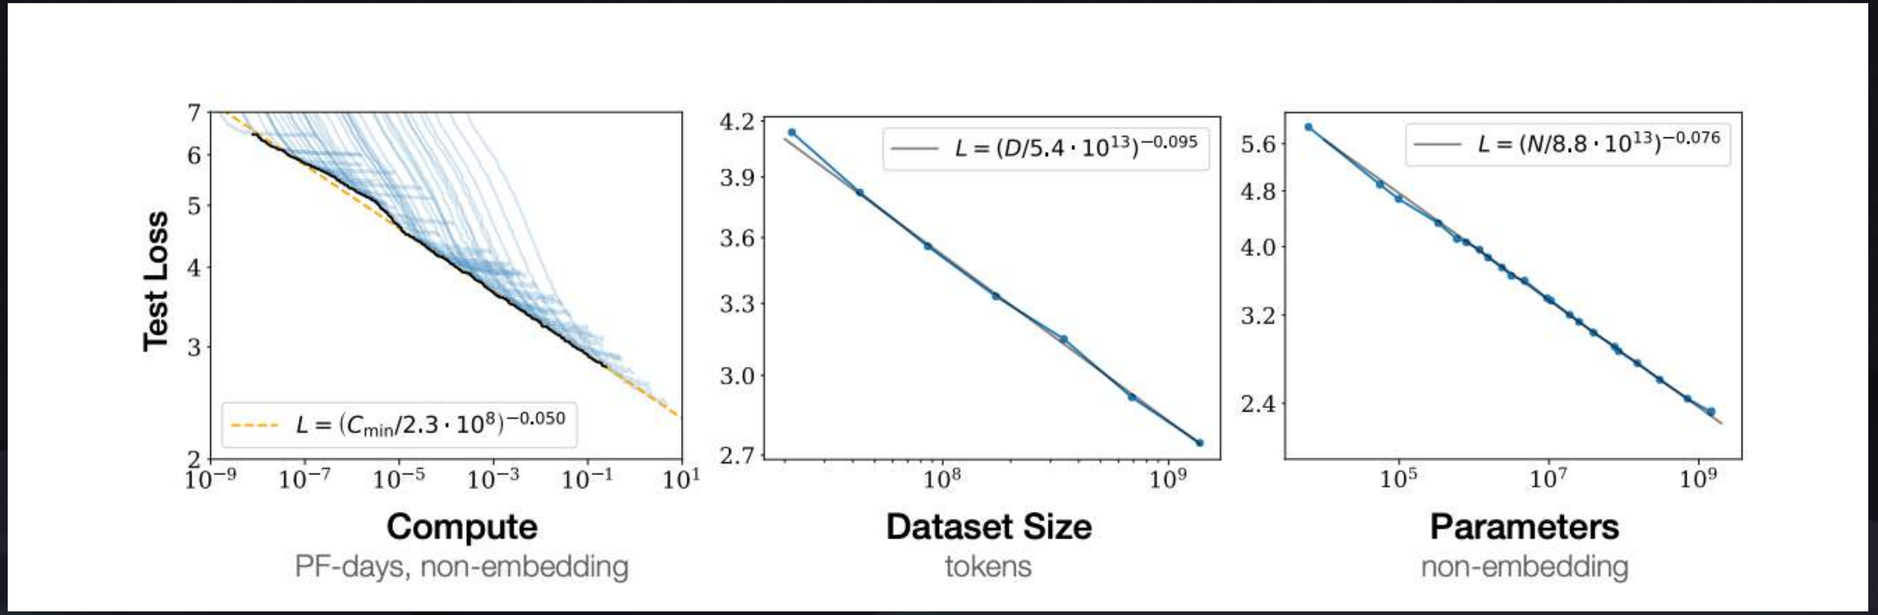
E nel mondo della programmazione?

1. exec_command — Esegue comandi shell.
2. apply_patch — Crea, modifica ed elimina file.
3. write_stdin — Interagisce con processi già avviati.
4. update_plan — Gestisce task e avanzamento.
5. view_image — Analizza immagini e screenshot.
6. web_search — Cerca informazioni online.
7. tool_search — Scopre altri tool disponibili.
8. spawn_agent — Avvia sub-agenti paralleli.
9. send_input — Invia istruzioni ai sub-agenti.
10. wait_agent — Attende i risultati dei sub-agenti.

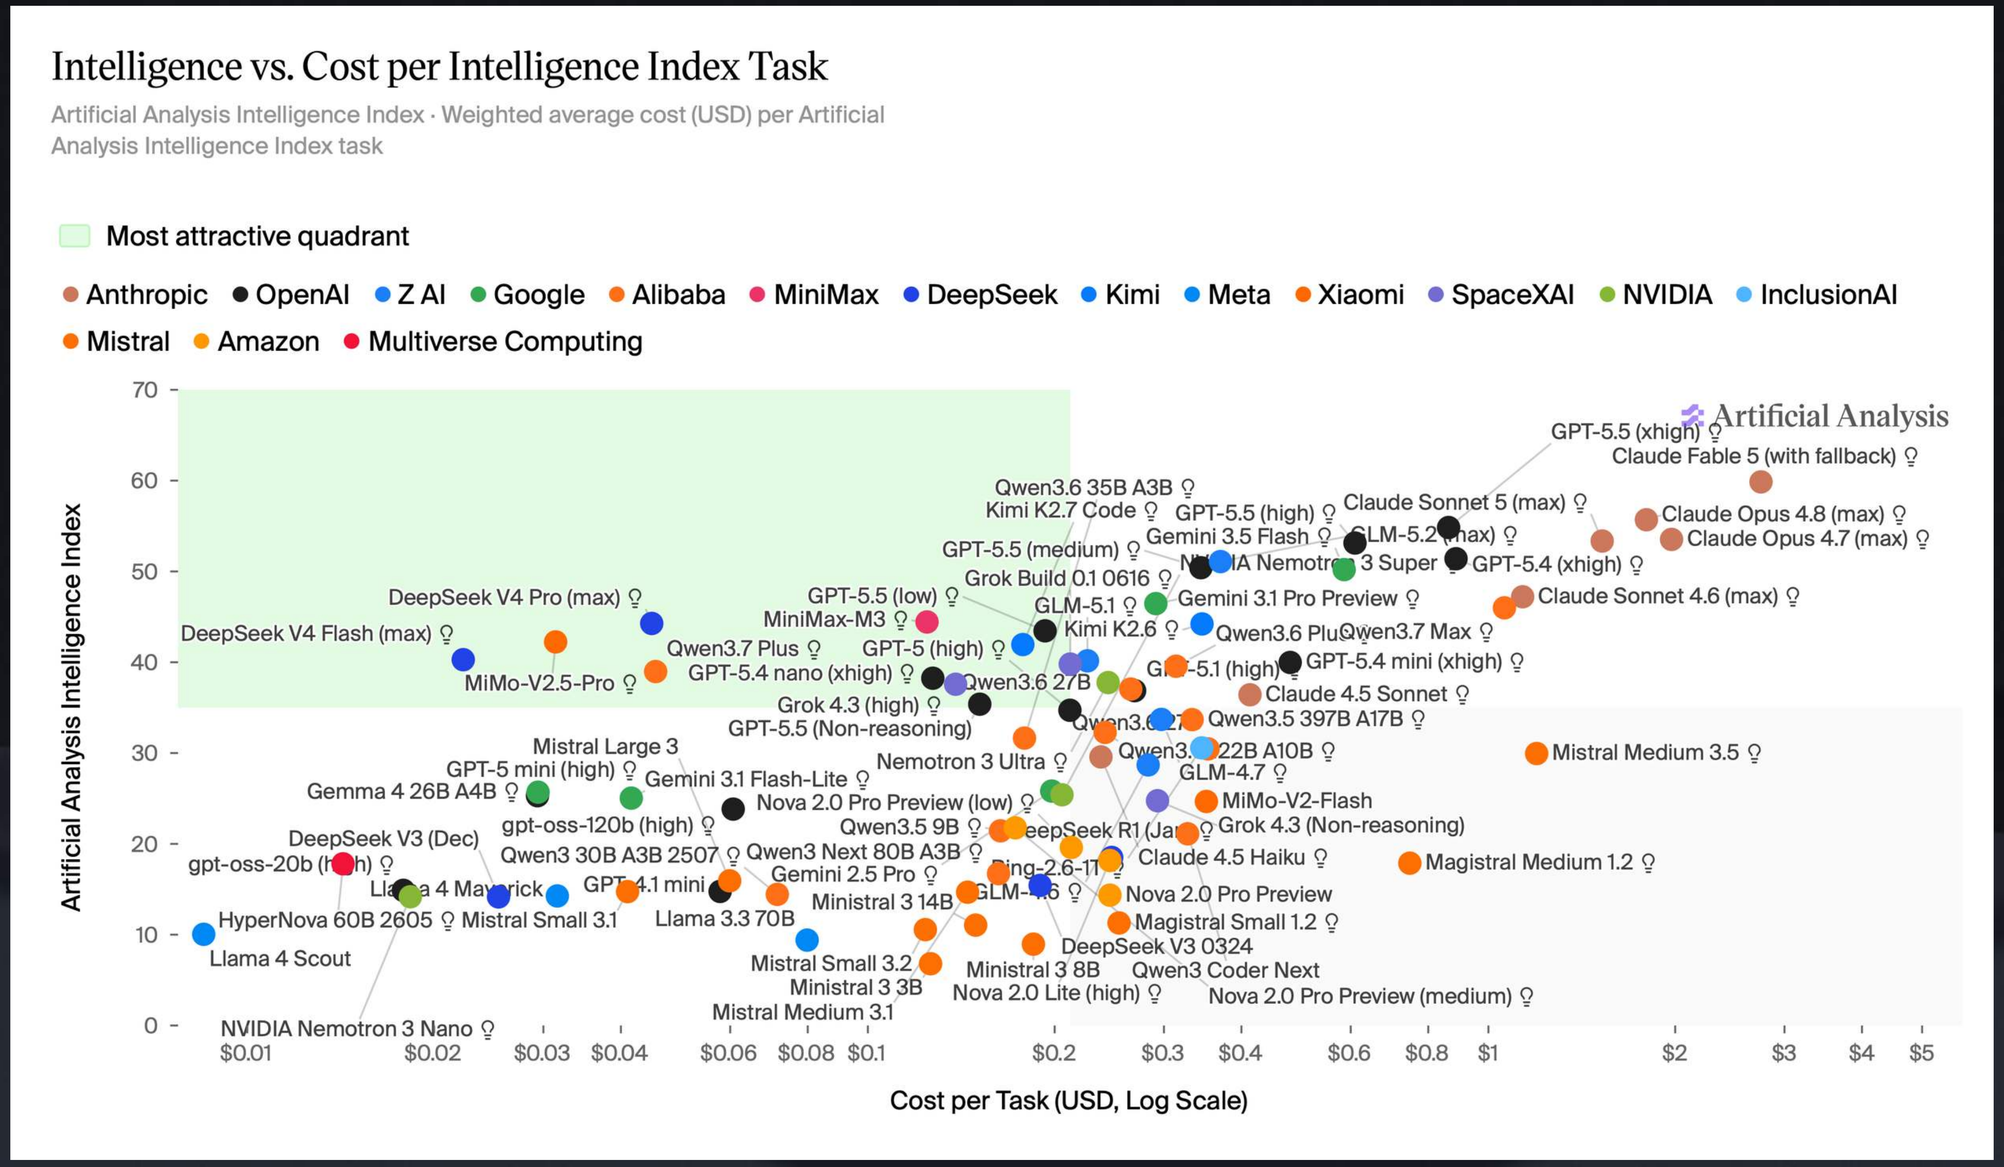
Il grande problema dell’AI

Allucinazioni: quando un modello da una risposta senza avere una fonte valida

Numero di parametri e prestazioni

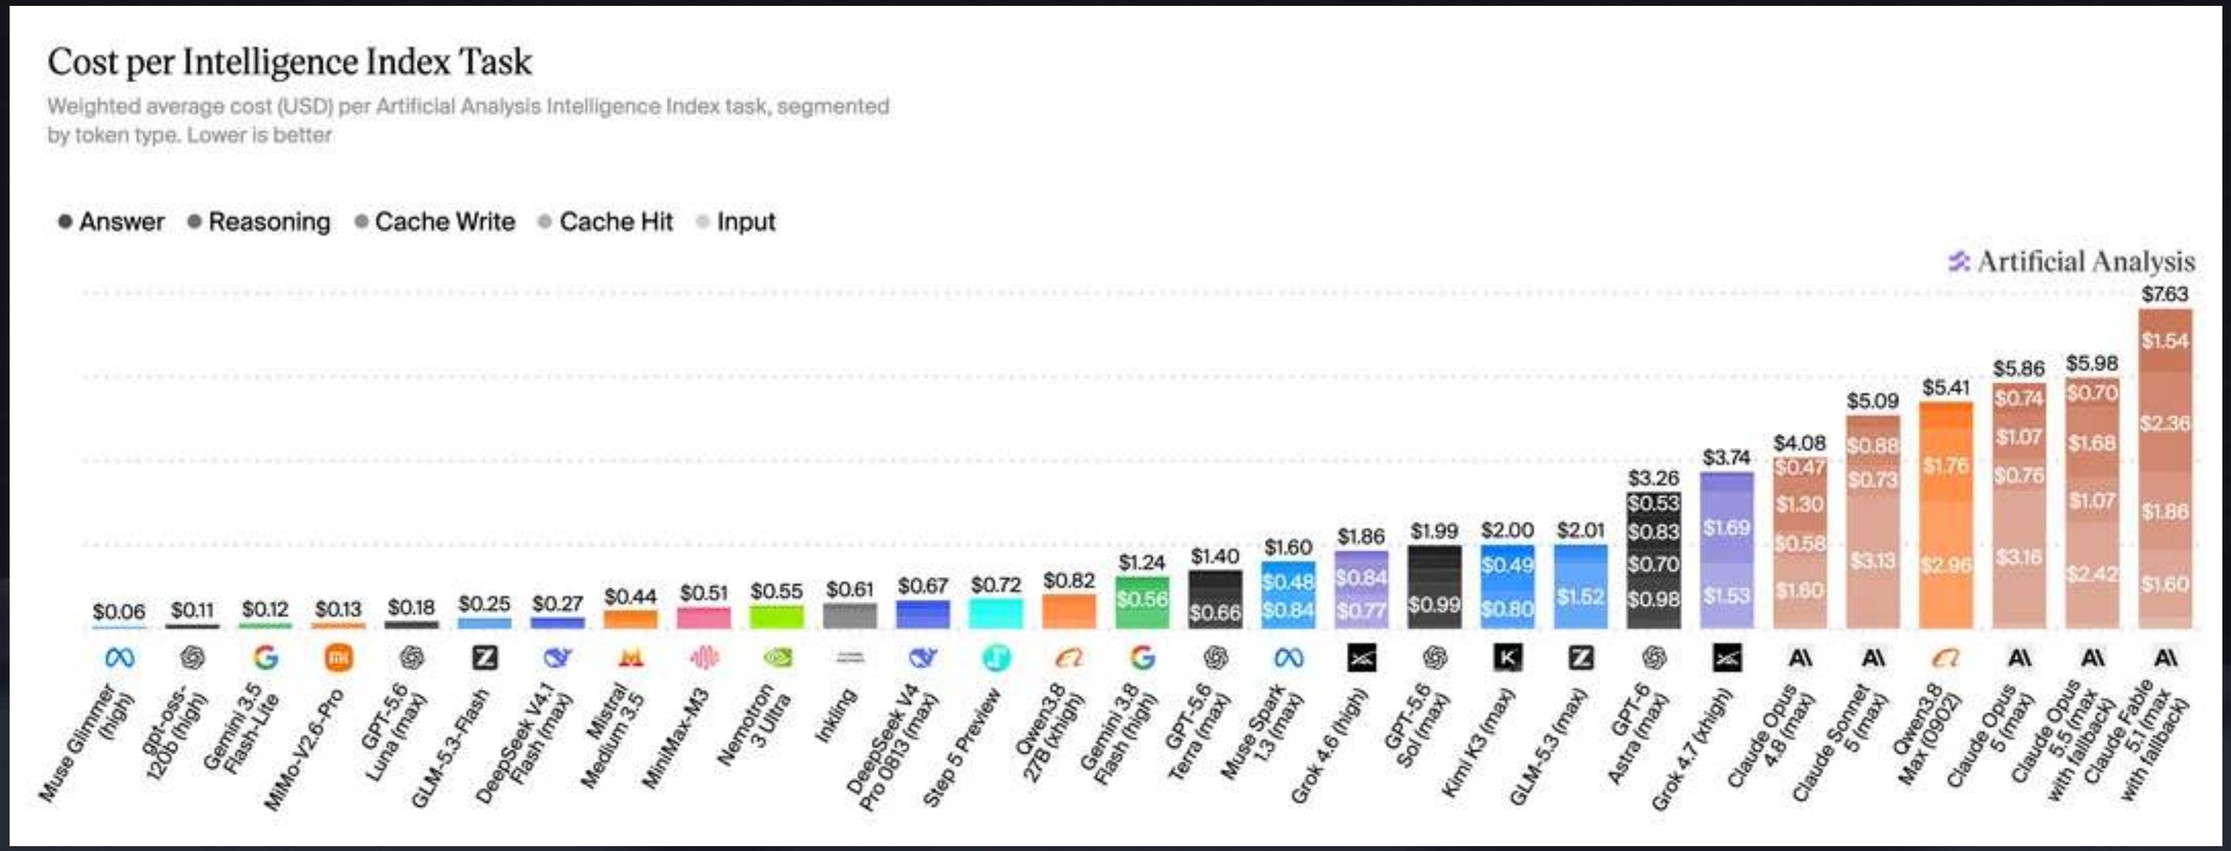


Costi e Prestazioni



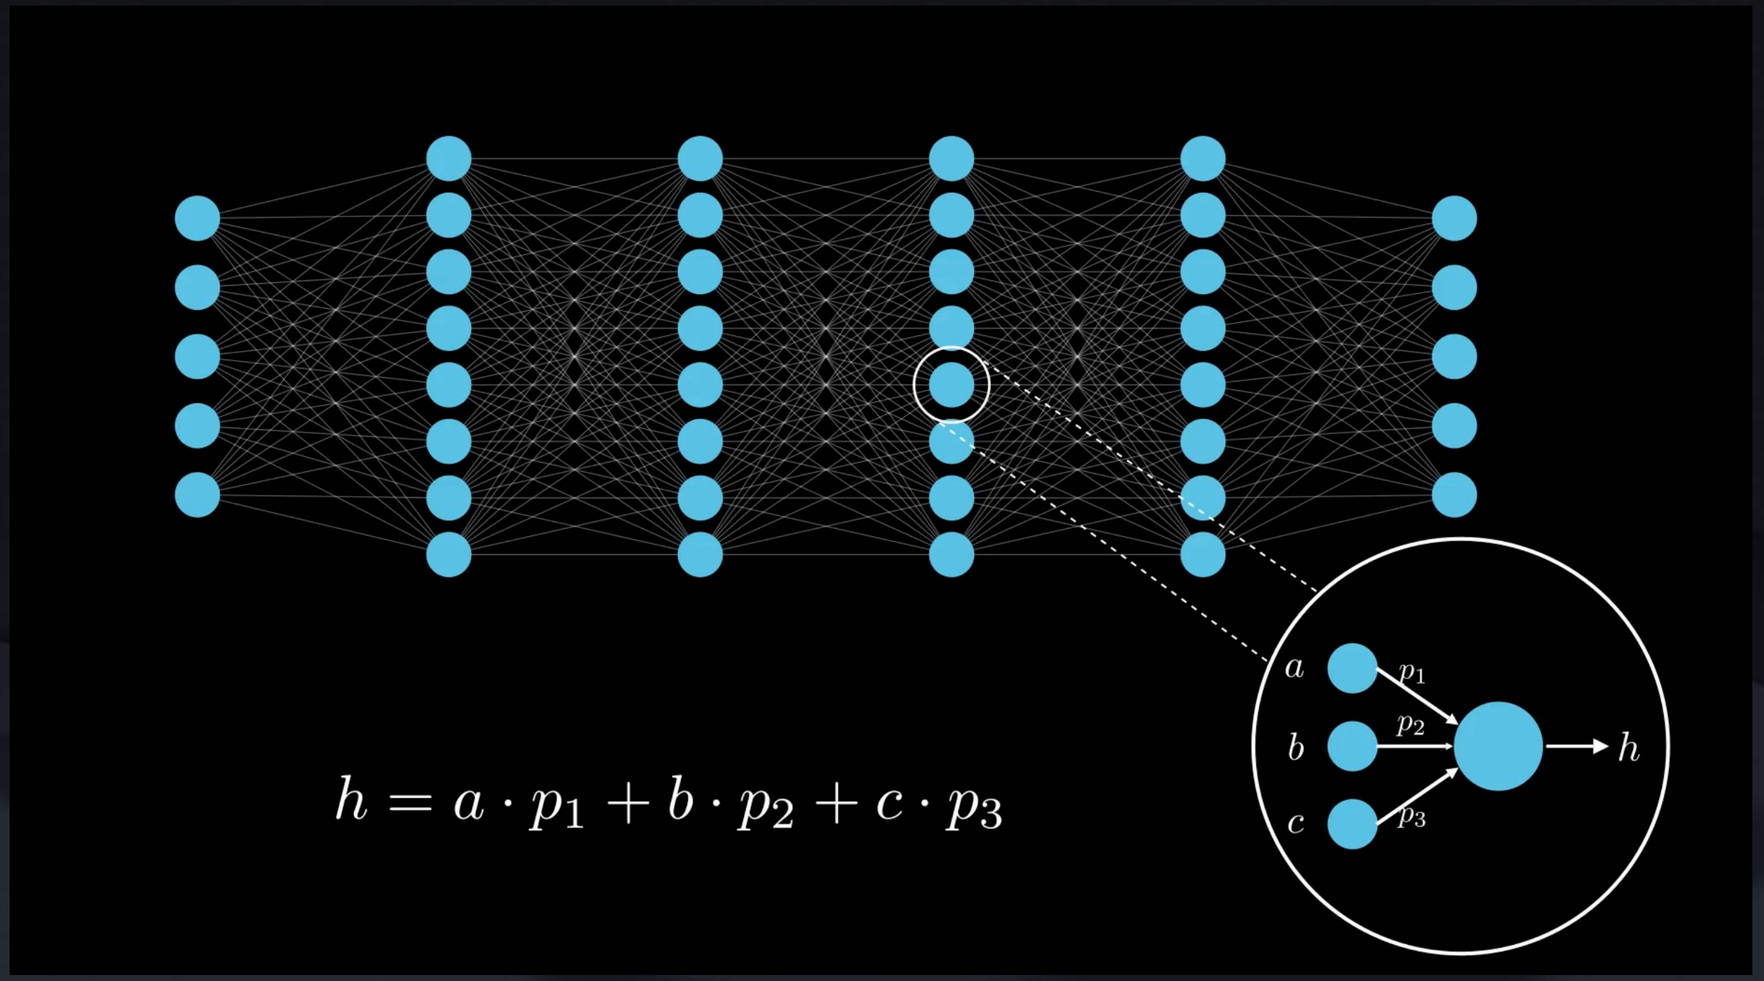
Da dove deriva il costo dei token

Modelli di riferimento a diverso budget



Una rete neurale fully connected

Le moltiplicazioni tra matrici.



Il prefill (lettura) avviene tutto in parallelo.
Il decode (scrittura) avviene uno alla volta in serie.



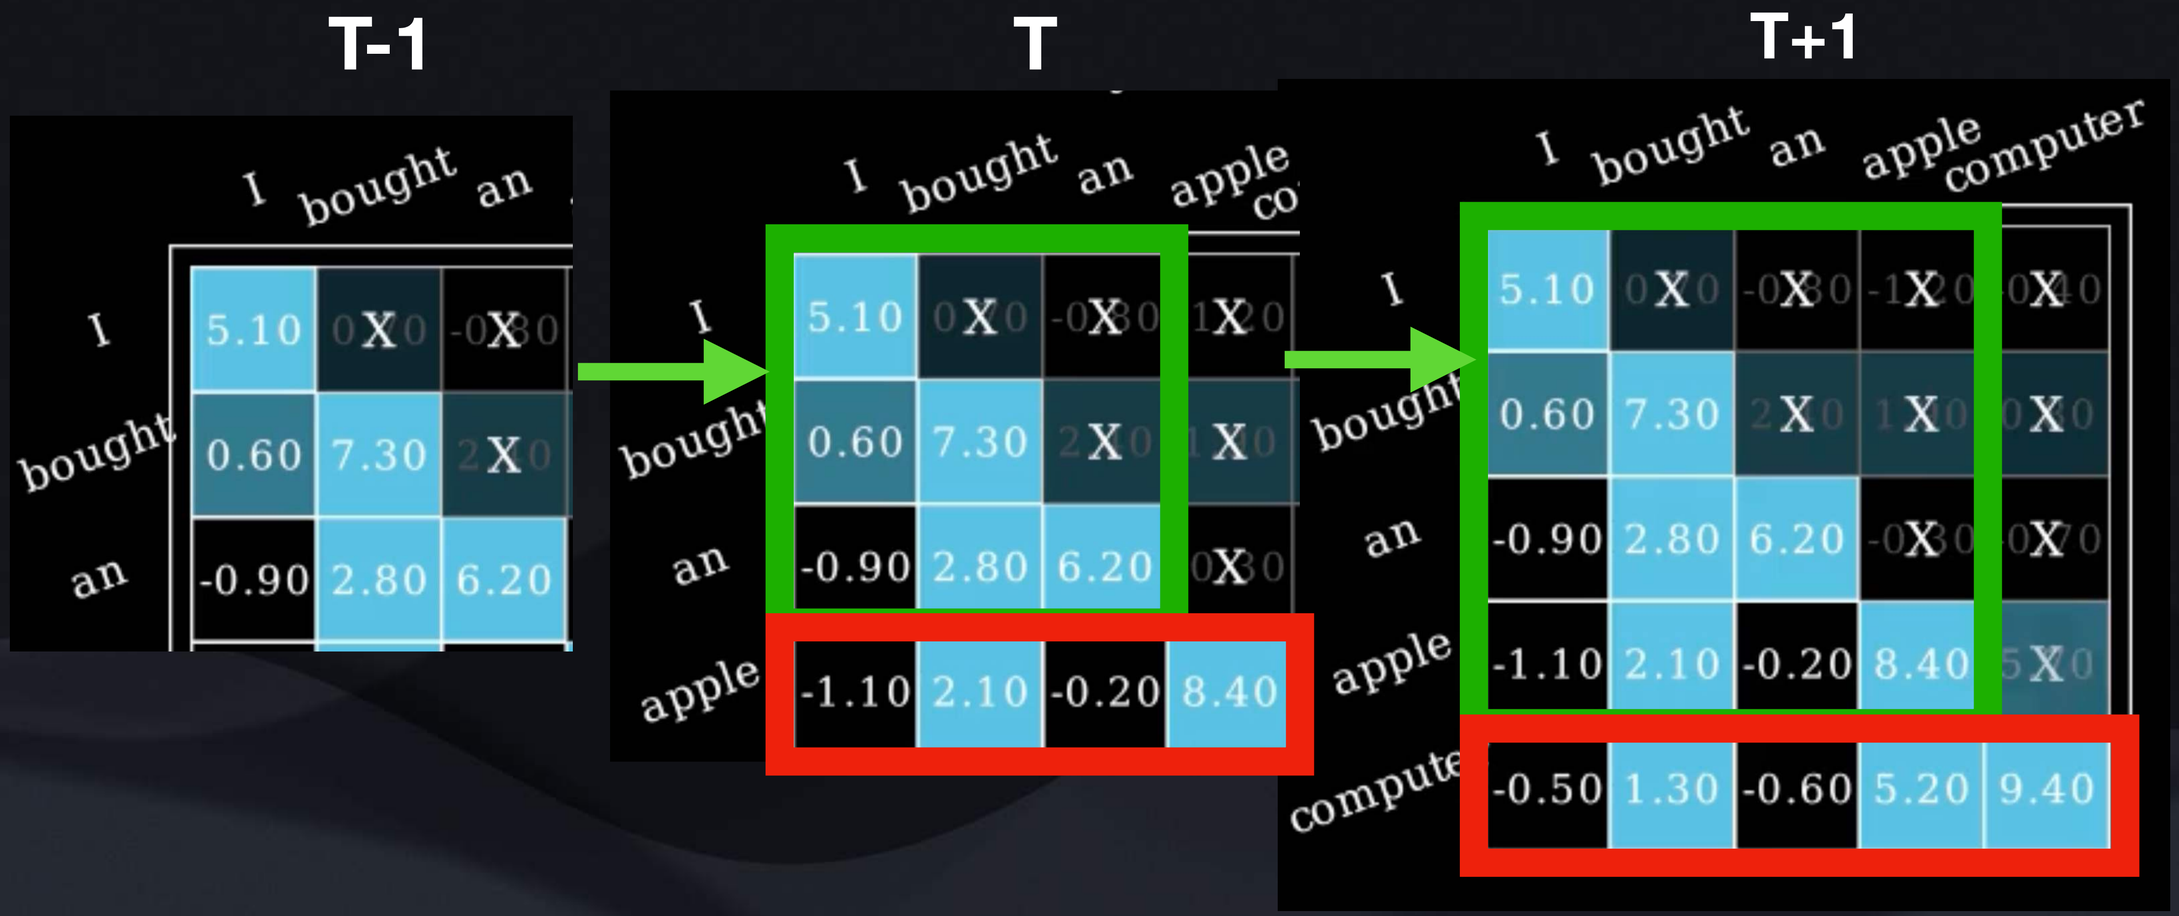
Pausa presentazione

Vediamo delle animazioni, non spaventatevi

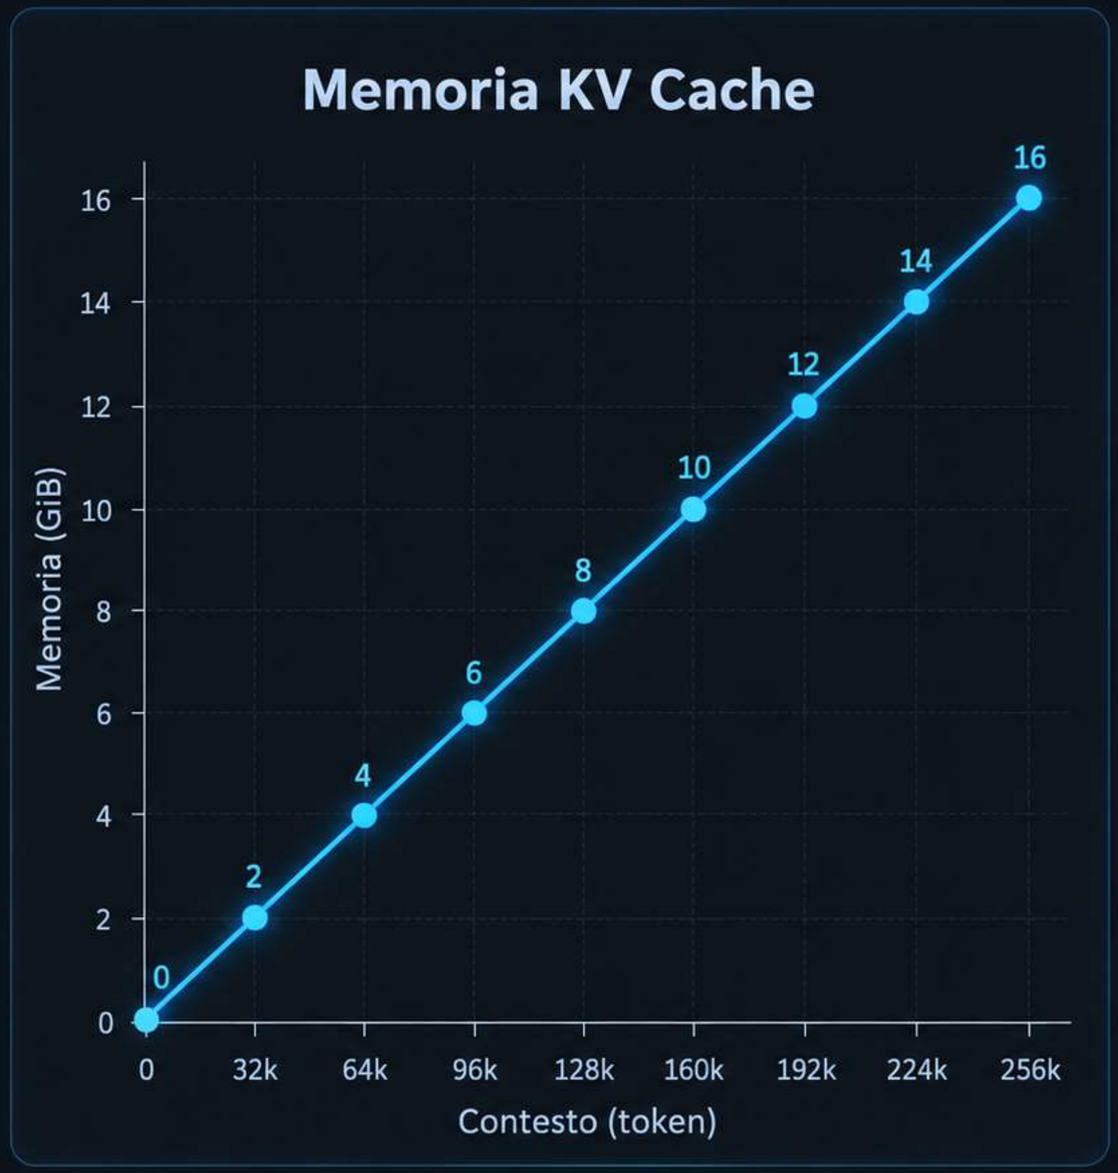
*(Values in this attention matrix are AI generated)

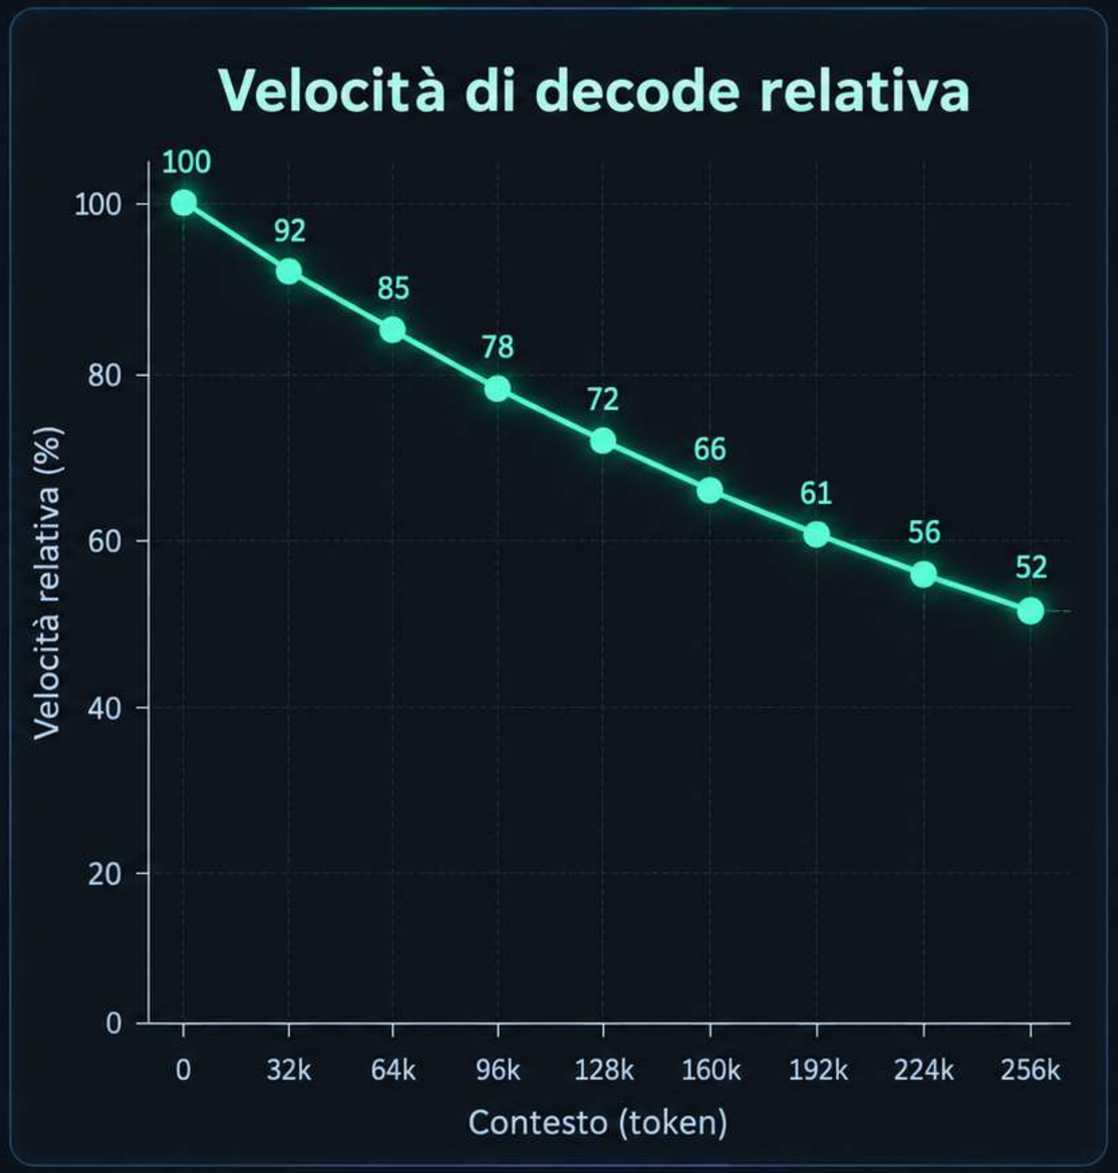
KV Cache

Looking at the attention matrices at steps t-1, t and t+1



The only part that changes is the last token, we don’t need to recompute the whole matrix


Memoria KV Cache
Memoria (GiB)
0
2
4
6
8
10
12
14
16
0
32k
64k
96k
128k
160k
192k
224k
256k
Contesto (token)


Velocità di decode relativa
Velocità relativa (%)
0
20
40
60
80
100
100
92
85
78
72
66
61
56
52
0
32k
64k
96k
128k
160k
192k
224k
256k
Contesto (token)